

# Entropia

---

Informazione associata a valore  $x$  avente probabilità  $p(x)$  é

$$i(x) = \log_2 \frac{1}{p(x)}$$

Nota: Eventi meno probabili danno maggiore informazione

Entropia di v.c.  $X \sim P$ : informazione media elementi di  $\mathcal{X}$

$$H(X) = \sum_{x \in \mathcal{X}} p(x) i(x) = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x)$$

Rappresenta l'incertezza su esito  $X$

# Proprietà dell'entropia

---

- L'unità di misura dell'entropia sono i bits  
(Usiamo  $\log$  in base 2)
- Se si cambia la base del logaritmo, il valore dell'entropia cambia solo di un fattore costante

**Lemma**  $H_b(X) = \frac{H(X)}{\lg b}$

**Dim.**

$$\begin{aligned} H_b(X) &= \sum_{x \in \mathcal{X}} p(x) \lg_b \frac{1}{p(x)} = \sum_{x \in \mathcal{X}} p(x) \frac{\lg \frac{1}{p(x)}}{\lg b} \\ &= \frac{1}{\lg b} \sum_{x \in \mathcal{X}} p(x) \lg \frac{1}{p(x)} = \frac{H(X)}{\lg b} \end{aligned}$$

□

# Entropia Binaria (v.c. di Bernulli)


$$X = \begin{pmatrix} a & b \\ p & 1-p \end{pmatrix}$$

$$H(X) = p \lg \frac{1}{p} + (1-p) \lg \frac{1}{(1-p)} \stackrel{def}{=} h(p)$$

$$h'(p) = \lg \frac{1-p}{p}$$

$$h''(p) = -\frac{\log e}{p(1-p)}$$

$$h(p) \geq 2 \min\{p, 1-p\}$$



## Entropia congiunta

---

**Def.** Date due v.c.  $X$  e  $Y$  con d.d.p. congiunta  $p(x, y)$ , definiamo *entropia congiunta* la quantità :

$$H(X, Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \lg \frac{1}{p(x, y)} = E \left[ \lg \frac{1}{p(X, Y)} \right]$$

$p(x, y)$	$y = 0$	$y = 1$
$x = 0$	1/4	1/4
$x = 1$	1/2	0

$$\begin{aligned} H(X, Y) &= H(1/4, 1/4, 1/2) \\ &= 2 \frac{1}{4} \log 4 + \frac{1}{2} \log 2 = \frac{3}{2} \text{ bits} \end{aligned}$$

# Entropia condizionata

*Entropia condizionata*  $H(Y/X)$ :

$$H(Y/X) = \sum_{x \in \mathcal{X}} p(x) H(Y/X = x)$$

$H(Y/X = x)$ : entropia di  $Y$  sapendo che  $X = x$

$p(x, y)$	$y = 0$	$y = 1$	$p(x)$	$H(Y/X = x)$
$x = 0$	1/2	1/4	3/4	$H(2/3, 1/3) = h(1/3)$
$x = 1$	1/4	0	1/4	$H(1, 0) = h(1) = 0$

$$H(Y/X) = \frac{3}{4}h\left(\frac{1}{3}\right) + \frac{1}{4}h(1) = \frac{3}{4}h\left(\frac{1}{3}\right)$$

bits

$$p(y/x) = \frac{p(x, y)}{p(x)}$$

# Entropia condizionata

---


$$\begin{aligned} H(Y/X) &= \sum_{x \in \mathcal{X}} p(x) H(Y/X = x) \\ &= \sum_{x \in \mathcal{X}} p(x) \sum_{y \in \mathcal{Y}} p(y/x) \lg \frac{1}{p(y/x)} \\ &= \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x) p(y/x) \lg \frac{1}{p(y/x)} \\ &= \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x, y) \lg \frac{1}{p(y/x)} = E \left[ \lg \frac{1}{p(y/x)} \right] \end{aligned}$$

## Entropia condizionata

---

$$H(Y/X) = \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x, y) \lg \frac{1}{p(y/x)} = E \left[ \lg \frac{1}{p(y/x)} \right]$$

rappresenta l'informazione aggiuntiva media di  $Y$  nota  $X$ .



# Regola della catena

---

$$H(X, Y) = H(X) + H(Y/X)$$

$$\begin{aligned} H(X, Y) &= \sum_{x,y} p(x, y) \lg \frac{1}{p(x, y)} = \sum_{x,y} p(x, y) \lg \frac{1}{p(y/x) p(x)} \\ &= \sum_{x,y} p(x, y) \left[ \lg \frac{1}{p(x)} + \lg \frac{1}{p(y/x)} \right] \\ &= \sum_{x,y} p(x, y) \lg \frac{1}{p(x)} + \sum_{x,y} p(x, y) \lg \frac{1}{p(y/x)} \\ &= \sum_x \left( \sum_y p(x, y) \right) \lg \frac{1}{p(x)} + H(Y/X) \\ &= \sum_x p(x) \lg \frac{1}{p(x)} + H(Y/X) = H(X) + H(Y/X) \end{aligned}$$

---



## Regola della catena: dimostrazione alternativa

---

Consideriamo la seguente dimostrazione alternativa:

$$\begin{aligned} H(X, Y) &= E \left[ \lg \frac{1}{p(X, Y)} \right] = E \left[ \lg \frac{1}{p(Y/X)p(X)} \right] \\ &= E \left[ \lg \frac{1}{p(X)} + \lg \frac{1}{p(Y/X)} \right] \\ &= E \left[ \lg \frac{1}{p(X)} \right] + E \left[ \lg \frac{1}{p(Y/X)} \right] \\ &= H(X) + H(Y/X) \end{aligned}$$

Il log trasforma prodotti di probabilità in somme di entropie


# Mutua Informazione

---

Date due v.c.  $X$  e  $Y$  con d.p. congiunta  $p(x, y)$ , la *mutua informazione* è definita come

$$I(X; Y) \doteq H(X) - H(X|Y) = H(Y) - H(Y|X)$$

La mutua informazione rappresenta i bit di informazione che una delle variabili fornisce circa l'altra.



Nota: uso ";" (es  $I(X, Z; Y) \neq I(X; Z, Y)$ )

# Mutua Informazione

---

Es. Lanciamo 10 monete:

$X$  rappresenta i valori delle prime 7 monete,

$Y$  quelli delle ultime 5.

$$H(X) = 7 \quad H(Y) = 5, \quad H(X/Y) = 5 \quad H(Y/X) = 3$$

$$\Rightarrow I(X; Y) = I(Y; X) = 2$$

# Mutua Informazione

---

- $I(X; Y) = H(X) - H(X/Y) = H(Y) - H(Y/X) = I(Y; X)$

$$\begin{aligned} I(X; Y) - I(Y; X) &= H(X) - H(X/Y) - H(Y) + H(Y/X) \\ &= H(X) + H(Y/X) - (H(Y) + H(X/Y)) \\ &= H(X, Y) - H(X, Y) = 0 \end{aligned}$$

- $I(X; Y) = H(X) + H(Y) - H(X, Y)$

- $I(X; X) = H(X)$

# Mutua Informazione Condizionata

---

$$I(X; Y/Z) = H(X/Z) - H(X/YZ) = H(Y/Z) - H(Y/XZ)$$

Nota: Il condizionamento di  $Z$  si applica SIA ad  $X$  che ad  $Y$

$$\begin{aligned} I(X; Y/Z) &= H(X/Z) - H(X/YZ) \\ &= H(X/Z) - (H(X, Y/Z) - H(Y/Z)) \\ &= H(X/Z) + H(Y/Z) - H(X, Y/Z) \end{aligned}$$

Regola della catena per la mutua informazione

$$I(X_1, \dots, X_n; Y) = \sum_{i=1}^n I(X_i; Y/X_1, \dots, X_{i-1})$$

Nota:

$$I(X_1, \dots, X_n; Y) = H(X_1, \dots, X_n) + H(Y) - H(X_1, \dots, X_n, Y)$$

# Riepilogo/Anteprima

---

N.B.: Le disuguaglianze saranno provate in seguito

**Entropia**  $H(X) = \sum_{x \in \mathcal{X}} p(x) \log \frac{1}{p(x)}$

- $H(X) \geq 0$ , uguaglianza sse  $\exists x$  t.c.  $p(x) = 1$
- $H(X) \leq \log |\mathcal{X}|$ , uguaglianza sse  $p(x) = 1/|\mathcal{X}| \forall x \in \mathcal{X}$
- Il condizionamento non aumenta l'entropia  
 $H(X/Y) \leq H(X)$  uguaglianza sse  $X, Y$  indipendenti
- Regola della catena:  
 $H(X, Y) = H(X) + H(Y/X) \leq H(X) + H(Y)$ ,  
uguaglianza sse  $X, Y$  indipendenti  
 $H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i/X_{i-1} \dots x_1) \leq \sum_{i=1}^n H(X_i)$ ,  
uguaglianza sse  $X_1, \dots, X_n$  indipendenti

# Riepilogo/Anteprima

---

## Mutua Informazione:

$$I(X; Y) = H(X) - H(X/Y) = H(X) + H(Y) - H(X, Y)$$

- Simmetrica e positiva:  $I(X; Y) = I(Y; X) \geq 0$ ,  
uguaglianza sse  $X, Y$  indipendenti

Infatti

$$I(X; Y) = H(X) - H(X/Y) \geq H(X) - H(X) = 0$$

con  $H(X/Y) = H(X)$  sse  $X, Y$  indipendenti

## Funzioni concave/convesse

---

**Def.** Una funzione  $f(x)$  si dice **concava** su un intervallo  $(a, b)$  se  $\forall x_1, x_2 \in (a, b)$  e  $\forall 0 \leq \lambda \leq 1$

$$f(\lambda \cdot x_1 + (1 - \lambda) \cdot x_2) \geq \lambda \cdot f(x_1) + (1 - \lambda) \cdot f(x_2)$$


$f$  è **strettamente concava** se la disuguaglianza è stretta per  $0 < \lambda < 1$ .

**Esempio**  $\lg x$  è una funzione strettamente concava di  $x$ .


**Def.** Una funzione  $f(x)$  si dice **convessa** su un intervallo  $(a, b)$  se  $-f(x)$  è concava sull'intervallo  $(a, b)$ .

**Esempio**  $x^2, x \lg x$  sono funzioni strett. convesse di  $x$ .





Concava  $\Rightarrow$   $f$  sopra  
la corda



Convessa  $\Rightarrow$   $f$  sotto  
la corda

# Diseguaglianza di Jensen

---

$$X = \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix} \quad f: \text{funzione}$$

$$f(X) = \begin{pmatrix} f(x_1) & f(x_2) & \dots & f(x_n) \\ p_1 & p_2 & \dots & p_n \end{pmatrix}.$$

- Risulta  $E[f(X)] \leq f(E[X])$ ,
- Se  $f$  strettamente concava:  $E[f(X)] = f(E[X])$ , sse  $X$  è concentrata in un' unico punto (cioé é costante)

---

La dimostrazione procede per induzione su  $|\mathcal{X}|$ .

**Base induzione:**  $|\mathcal{X}| = 2$ .

Si consideri la v.c.

$$X = \begin{pmatrix} x_1 & x_2 \\ p_1 & p_2 \end{pmatrix}$$

Per la definizione di funzione concava, si ha che

$$E[f(X)] = p_1 f(x_1) + p_2 f(x_2) \leq f(p_1 x_1 + p_2 x_2) = f(E[X]).$$

Se  $f$  strett. concava l'uguaglianza vale sse  $p_1 = 1$  oppure  $p_2 = 1$ .

---

**Passo induttivo:** Supponiamo che la disuguaglianza di Jensen sia verificata per  $|\mathcal{X}| = k - 1$ . Dimostriamo che la disuguaglianza è verificata per  $|\mathcal{X}| = k$ .

$$\begin{aligned} E[f(X)] &= \sum_{i=1}^k p_i f(x_i) = p_k f(x_k) + \sum_{i=1}^{k-1} p_i f(x_i) \\ &= p_k f(x_k) + (1 - p_k) \left( \sum_{i=1}^{k-1} \frac{p_i}{(1 - p_k)} f(x_i) \right) \end{aligned}$$

---

Osserviamo che  $\sum_{i=1}^{k-1} \frac{p_i}{(1-p_k)} f(x_i) = E[f(X')]$  dove  $X'$  è la v.c.

$$X' = \begin{pmatrix} x_1 & \dots & x_{k-1} \\ \frac{p_1}{1-p_k} & \dots & \frac{p_{k-1}}{1-p_k} \end{pmatrix}$$

L'ipotesi induttiva implica  $E[f(X')] \leq f(E[X'])$  per cui risulta:

$$E[f(X)] \leq p_k f(x_k) + (1 - p_k) f\left(\sum_{i=1}^{k-1} \frac{p_i}{1 - p_k} x_i\right).$$

Applichiamo la definizione di funzione concava al termine destro

---

Otteniamo

$$\begin{aligned} E[f(X)] &\leq f\left(p_k x_k + (1 - p_k) \sum_{i=1}^{k-1} \frac{p_i}{1 - p_k} x_i\right) \\ &= f\left(\sum_{i=1}^k p_i x_i\right) = f(E[X]). \end{aligned}$$

Se  $f$  **strettamente concava**: uguaglianza sse tutti  $\leq$  sono =

- (= in def.  $f$  concava):  $p_k = 1$  o  $p_k = 0$  (cioé  $\sum_{i=1}^{k-1} p_i = 1$ )  
se  $p_k = 1 \Rightarrow X$  concentrata in un'unico punto (cioé  $x_k$ )
- (= in i.i.):  $p_k = 0$  e, per i.i.,  $X'$  concentrata in un'unico punto  
 $\Rightarrow X$  concentrata in un'unico punto (tra  $x_1 \dots x_{k-1}$ ).

# Proprietà dell'entropia

---

**Lemma.** Sia  $X \sim P$  v.c. con alfabeto  $\mathcal{X}$ .

1.  $H(X) \geq 0$ ; uguaglianza sse  $\exists x \in \mathcal{X}$  t.c.  $p(x) = 1$ .
2.  $H(X) \leq \lg |\mathcal{X}|$ ;  
l'uguaglianza vale sse  $X$  è uniformemente distribuita.

**Dim.** Punto 1.

- $0 \leq p(x) \leq 1 \Rightarrow \log \frac{1}{p(x)} \geq 0 \Rightarrow \sum_x p(x) \log \frac{1}{p(x)} \geq 0$
- **Esiste**  $x \in \mathcal{X}$  con  $0 < p(x) < 1$  sse  $H(x) > 0$

## Dim. punto 2.

$$\begin{aligned} H(X) &= E \left( \lg \frac{1}{P(X)} \right) \\ &\leq \lg E \left( \frac{1}{P(X)} \right) \quad \text{disug. Jensen su } \lg \text{ e } \begin{pmatrix} \cdots & \frac{1}{p(x)} & \cdots \\ \cdots & p(x) & \cdots \end{pmatrix} \\ &= \lg \sum_{x \in \mathcal{X}} p(x) \frac{1}{p(x)} = \lg \sum_{x \in \mathcal{X}} 1 = \lg |\mathcal{X}|. \end{aligned}$$

La disuguglianza di Jensen vale con il segno di “=” sse  $\frac{1}{p(x)} = c$  costante,  $\forall x \in \mathcal{X}$ .

$$\frac{1}{p(x)} = c \Rightarrow p(x) = \frac{1}{c} \Rightarrow 1 = \sum_{x \in \mathcal{X}} p(x) = \sum_{x \in \mathcal{X}} \frac{1}{c} = \frac{|\mathcal{X}|}{c}.$$

Quindi  $c = |\mathcal{X}|$  e  $p(x) = \frac{1}{c} = \frac{1}{|\mathcal{X}|}$ .



# Condizionamento non aumenta entropia

---

$H(Y/X) \leq H(Y)$ , uguaglianza sse  $X$  e  $Y$  indipendenti

$$\begin{aligned} H(Y/X) - H(Y) &= \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x, y) \lg \frac{1}{p(y/x)} - \sum_{y \in \mathcal{Y}} p(y) \lg \frac{1}{p(y)} \\ &= \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x, y) \lg \frac{1}{p(y/x)} - \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x, y) \lg \frac{1}{p(y)} \\ &= \sum_{x, y} p(x, y) \lg \frac{p(y)}{p(y/x)} \leq \lg \sum_{x, y} p(x, y) \frac{p(y)}{p(y/x)} \\ &= \lg \sum_{x, y} \frac{p(y/x)p(x)p(y)}{p(y/x)} = \lg \sum_{x, y} p(x)p(y) \\ &= \lg \sum_x p(x) \sum_y p(y) = \lg \sum_x p(x) = \lg 1 = 0 \end{aligned}$$

---

---

La disuguaglianza di Jensen applicata a  $\begin{pmatrix} \cdots & \frac{p(y)}{p(y/x)} & \cdots \\ \cdots & p(x, y) & \cdots \end{pmatrix}$   
vale con il segno di “=” sse  $\frac{p(y)}{p(y/x)} = c$  costante,  $\forall x, y$ .

$$\frac{p(y)}{p(y/x)} = c \quad \Rightarrow \quad p(y) = c p(y/x)$$

Sommando su  $y$

$$1 = \sum_{y \in \mathcal{Y}} p(y) = \sum_{y \in \mathcal{Y}} c p(y/x) = c \sum_{y \in \mathcal{Y}} p(y/x) = c$$

Quindi  $p(y) = p(y/x)$ ,  $\forall x, y$ , cioè  $X, Y$  sono indipendenti.

---

**Corollario**  $H(X, Y) \leq H(X) + H(Y)$

**Corollario**

$$H(X, Y/Z) = \sum_{x,y,z} p(xyz) \log \frac{1}{p(xy/z)} = H(X/Z) + H(Y/X, Z)$$

**Dim.** (lasciata come esercizio)

**Nota:** In generale non è vero che  $H(X/Y) = H(Y/X)$ .

## Estensione Regola della catena

---

**Teorema** Siano  $X_1, \dots, X_n$   $n$  v.c. con d.d.p.  $p(x_1, \dots, x_n)$

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i / X_{i-1} \dots X_1)$$

**Dim.**

Procediamo per induzione su  $n$ .

Per  $n = 2$ , applicando la regola della catena abbiamo

$$H(X_1, X_2) = H(X_1) + H(X_2 / X_1)$$

---

Iterando (assumiamo l'asserto vero per  $n - 1$ )

$$\begin{aligned} H(X_1, \dots, X_n) &= H(X_n/X_1, \dots, X_{n-1}) + H(X_1, \dots, X_{n-1}) \\ &= H(X_n/X_{n-1} \dots X_1) + H(X_{n-1}/X_{n-2} \dots X_1) \\ &\quad + \dots + H(X_2/X_1) + H(X_1) \\ &= \sum_{i=1}^n H(X_i/X_{i-1}, \dots, X_1) \end{aligned}$$

□

---

## Teorema

$$H(X_1, \dots, X_n) \leq \sum_{i=1}^n H(X_i),$$

l'uguaglianza vale sse  $X_1, \dots, X_n$  sono indipendenti.

**Dim.**

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i / X_1, \dots, X_{i-1}) \leq \sum_{i=1}^n H(X_i)$$

L'ultima disuguaglianza vale con il segno di “=” sse  $X_1, \dots, X_n$  sono indipendenti. □

# Divergenza informativa

---

**Def.** Date due d.d.p.  $p(x)$  e  $q(x)$ ,  
*la divergenza informativa*  
(o *entropia relativa*, o *distanza Kullback Leibler*)  
 $D(p||q)$  di  $p(x)$  e  $q(x)$  è definita come

$$D(p||q) = \sum_{x \in \mathcal{X}} p(x) \lg \frac{p(x)}{q(x)}$$

Divergenza  $D(p||q)$  misura la distanza tra le due d.p.  $p$  e  $q$ .  
Non é simmetrica, infatti in generale  $D(p||q) \neq D(q||p)$

$$D(p||q) \geq 0 \text{ con l'uguaglianza sse } p = q$$

---

Proviamo  $-D(p||q) \leq 0$  usando la disuguaglianza di Jensen:

$$\begin{aligned} -D(p||q) &= \sum_{x \in \mathcal{X}} p(x) \lg \frac{q(x)}{p(x)} \leq \lg \sum_{x \in \mathcal{X}} p(x) \frac{q(x)}{p(x)} \\ &= \lg \sum_{x \in \mathcal{X}} q(x) = 0 \end{aligned}$$

dove dis. Jensen applicata a v.c.  $\begin{pmatrix} \cdots & \frac{q(x)}{p(x)} & \cdots \\ \cdots & p(x) & \cdots \end{pmatrix}$ :

Uguaglianza sse  $\frac{q(x)}{p(x)} = c = \text{costante} \quad \forall x$ ,

da cui  $1 = \sum_x q(x) = c \sum_x p(x) = c$ .

Quindi  $c = 1$  e  $q(x) = p(x), \forall x$ .



---

Date due v.c.  $X$  e  $Y$  con probabilità congiunta  $p(x, y)$ , la *mutua informazione* corrisponde all'entropia relativa tra  $p(x, y)$  e  $p(x)p(y)$ :

$$\begin{aligned} I(X; Y) &= H(X) + H(Y) - H(X, Y) \\ &= \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x, y) \lg \frac{p(x, y)}{p(x) p(y)} \\ &= D(p(x, y) || p(x)p(y)) \end{aligned}$$

# Esempio

## Esempio

$Y \setminus X$	1	2	3	4
1	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{32}$	$\frac{1}{32}$
2	$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{32}$	$\frac{1}{32}$
3	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$
4	$\frac{1}{4}$	0	0	0

---

Determiniamo le d.d.p. marginali.

Sommando le probabilità in ciascuna colonna:

$$X = \begin{pmatrix} 1 & 2 & 3 & 4 \\ \frac{1}{2} & \frac{1}{4} & \frac{1}{8} & \frac{1}{8} \end{pmatrix}$$

Sommando le probabilità in ciascuna riga:

$$Y = \begin{pmatrix} 1 & 2 & 3 & 4 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{pmatrix}$$

---

$$\begin{aligned}
 H(X/Y) &= \sum_{i=1}^4 p(y=i) H(X/Y=i) \\
 &= \frac{1}{4} H\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\right) + \frac{1}{4} H\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\right) \\
 &\quad + \frac{1}{4} H\left(\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4}\right) + \frac{1}{4} H(1, 0, 0, 0) \\
 &= \frac{1}{4} \left[ \frac{1}{2} + \frac{1}{4} \cdot 2 + 2 \cdot \frac{1}{8} \cdot 3 \right] 2 + \frac{1}{4} \lg 4 + \frac{1}{4} 0 \\
 &= \frac{1}{4} \left[ \frac{1}{2} + \frac{1}{2} + \frac{3}{4} \right] 2 + \frac{1}{2} = \frac{1}{2} \left[ \frac{7}{4} \right] + \frac{1}{2} = \frac{11}{8}
 \end{aligned}$$

---

---

$$H(Y/X) = \frac{13}{8}$$

$$H(X, Y) = H(Y) + H(X/Y) = 2 + \frac{11}{8} = \frac{27}{8}$$

$$\begin{aligned} I(X; Y) &= H(X) - H(X/Y) = \frac{7}{4} - \frac{11}{8} = \frac{3}{8} \\ &= H(Y) - H(Y/X) = 2 - \frac{13}{8} = \frac{3}{8} \end{aligned}$$

## Esercizio

---

**Esercizio** Dimostrare che, data la funzione  $f$ , risulta

$$H(X) \geq H(f(X))$$

Suggerimento: considerare  $H(X, f(X))$

## Esempio

---

Condizioni meteo modellate da v.c.  $X = \begin{pmatrix} x_p & x_n \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$

Yari esce con ombrello in accordo alla v.c.

$$Y = \begin{pmatrix} y_o & y_n \\ p(y_o) & p(y_n) \end{pmatrix} \text{ con } [p(y/x)] = \begin{array}{c|cc} X \backslash Y & y_o & y_n \\ \hline x_p & \frac{1}{3} & \frac{2}{3} \\ x_n & 1 & 0 \end{array}$$

Abbiamo  $P(y_o) = p(x_p)p(y_o/x_p) + p(x_n)p(y_o/x_n) = 2/3$ ,

quindi  $Y = \begin{pmatrix} y_o & y_n \\ \frac{2}{3} & \frac{1}{3} \end{pmatrix}$

---


$$X = \begin{pmatrix} x_p & x_n \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}, \quad Y = \begin{pmatrix} y_o & y_n \\ \frac{2}{3} & \frac{1}{3} \end{pmatrix},$$

$X \backslash Y$	$y_o$	$y_n$
$x_p$	$\frac{1}{3}$	$\frac{2}{3}$
$x_n$	1	0

**Risulta**

$$H(X) = 1, \quad H(Y) = h\left(\frac{1}{3}\right)$$

$$H(Y/X) = \sum_x p(x) H(Y/X = x) = \frac{1}{2} h\left(\frac{1}{3}\right) + \frac{1}{2} h(1) = \frac{1}{2} h\left(\frac{1}{3}\right)$$

$$I(X; Y) = H(Y) - H(Y/X) = h\left(\frac{1}{3}\right) - \frac{1}{2} h\left(\frac{1}{3}\right) = \frac{1}{2} h\left(\frac{1}{3}\right)$$



---

Zelda per indovinare che tempo fa osserva Yari:

- Se Yari ha ombrello dice  $x_p$
- Se Yari non ha ombrello, lancia una moneta: se testa dice  $x_n$ , altr. dice  $x_p$

Previsione Zelda dipende solo dal comportamento di Yari!

Sia  $Z$  la v.c. che rappresenta la previsione di Zelda.

Per ogni  $x, y, z$

$$p(z/xy) = p(z/y)$$

Previsione  $Z$ (elda) fornisce meno informazione su  $X$  che l'osservazione diretta comportamento di  $Y$ (ari)!,

Formalmente

$$I(X; Z) \leq I(X; Y)$$

# Catene di Markov

---

$X, Y, Z$  formano una catena di Markov ( $X \rightarrow Y \rightarrow Z$ )  
sse

$Z$  é condizionalmente indipendente da  $X$  noto  $Y$ ,  
formalmente

$$p(z/xy) = p(z/y), \quad \forall x, y, z$$

# Teorema del Data Processing

---

Esercizio:  $X \rightarrow Y \rightarrow Z$  sse  $Z \rightarrow Y \rightarrow X$

Teorema(Data Processing) Se  $X \rightarrow Y \rightarrow Z$  allora

$$a) I(X; Z) \leq I(X; Y)$$

$$b) I(X; Z) \leq I(Z; Y)$$

**Dim.** Proviamo a).

Disuguaglianza b) segue applicando a) a  $Z \rightarrow Y \rightarrow X$ .

**Se  $X \rightarrow Y \rightarrow Z$  allora  $I(X; Z) \leq I(X; Y)$**

---

Poiché  $X \rightarrow Y \rightarrow Z$

$$H(X/YZ) = E[-\lg p(x/yz)] = E[-\lg p(x/y)] = H(X/Y)$$

Da cui

$$I(X; YZ) = H(X) - H(X/YZ) = H(X) - H(X/Y) = I(X; Y)$$

Inoltre

$$I(X; YZ) = H(X) - H(X/YZ) \geq H(X) - H(X/Z) = I(X; Z)$$

## Stima di v.c.

---

$$X = \begin{pmatrix} x_p & x_n \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}, \quad \begin{array}{c|cc} Y/X & y_o & y_n \\ \hline x_p & \frac{1}{3} & \frac{2}{3} \\ x_n & 1 & 0 \end{array}, \quad Y = \begin{pmatrix} y_o & y_n \\ \frac{2}{3} & \frac{1}{3} \end{pmatrix}$$

Zelda per indovinare che tempo fa osserva Yari:

- Se Yari ha ombrello dice  $x_p$
- Se Yari non ha ombrello dice  $x_n$

v.c.  $Z$  = stima Zelda fa di  $X$  conoscendo  $Y$ .

$$Z = g(Y) = \begin{cases} x_p & \text{se } Y = y_o \\ x_n & \text{se } Y = y_n \end{cases}$$

Quale é la probabilità che Zelda fa una stima esatta di  $X$ ?

# Disuguaglianza di Fano

---

Siano  $X, Y$  v.c.. Vogliamo stimare  $X$  dall'osservazione di  $Y$ .  
Osserviamo  $Y$ , calcoliamo  $g(Y) = \hat{X}$  (stima di  $X$ ).  
Probabilità  $X \neq \hat{X}$ ? Sia

$$P_e = \Pr\{\hat{X} \neq X\}$$

**Teorema** (Disuguaglianza di Fano)

$$h(P_e) + P_e \lg(|\mathcal{X}| - 1) \geq H(X|Y)$$

Nota: Teorema implica  $P_e \geq \frac{H(X|Y) - h(P_e)}{\lg(|\mathcal{X}| - 1)} \geq \frac{H(X|Y) - 1}{\lg(|\mathcal{X}|)}$

Nota:  $P_e = 0 \Rightarrow H(X|Y) = 0$

Nota:  $X \rightarrow Y \rightarrow \hat{X}$ .

---

**Dim.** . Definiamo la v.c. errore  $E$  t.c.

$$E = \begin{cases} 1 & \text{se } X \neq \hat{X} \\ 0 & \text{se } X = \hat{X} \end{cases}, \quad \text{cioé} \quad E = \begin{pmatrix} 1 & 0 \\ P_e & 1 - P_e \end{pmatrix}$$

$$\begin{aligned} H(X|Y) &= H(X|Y) + H(E|X, Y) = H(E, X|Y) \\ &= H(E|Y) + H(X|E, Y) \\ &\leq h(P_e) + H(X|E, Y) \end{aligned}$$

con

$$\begin{aligned} H(X|E, Y) &= Pr\{E = 0\}H(X|E = 0, Y) + Pr\{E = 1\}H(X|E = 1, Y) \\ &\leq (1 - P_e)0 + P_e \lg(|\mathcal{X}| - 1) = P_e \lg(|\mathcal{X}| - 1) \end{aligned}$$

---

# Riepilogo Misure di Informazione

---

**Entropia:**  $H(X) = \sum_{x \in \mathcal{X}} p(x) \log \frac{1}{p(x)}$

- Limiti:  $0 \leq H(X) \leq \log |\mathcal{X}|$ ,

- Il condizionamento non aumenta l'entropia:  
 $H(X/Y) \leq H(X)$

- Regola della catena:

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i / X_{i-1} \dots x_1) \leq \sum_{i=1}^n H(X_i),$$
$$H(X_1, \dots, X_n / Y_1, \dots, Y_n) \leq \sum_{i=1}^n H(X_i / Y_i)$$

**Divergenza informazionale:**  $D(p||q) = \sum_{x \in \mathcal{X}} p(x) \lg \frac{p(x)}{q(x)} \geq 0$



# Riepilogo Misure di Informazione

---

## Mutua Informazione:

$$\begin{aligned} I(X; Y) &= H(X) - H(X/Y) = H(X) + H(Y) - H(X, Y) \\ &= D(p(x, y) || p(x)p(y)) \end{aligned}$$

- Simmetrica e positiva:  $I(X; Y) = I(Y; X) \geq 0$ ,
- $X, Y$  indipendenti  $\Rightarrow I(X; Y) = H(X) - H(X/Y) = 0$
- $X \rightarrow Y \rightarrow Z \Rightarrow I(X; Z) \leq I(X; Y)$

## Fano:

- $X \rightarrow Y \rightarrow \hat{X}, P_e = Pr\{\hat{X} \neq X\} \Rightarrow$   
 $h(P_e) + P_e \lg(|\mathcal{X}| - 1) \geq H(X|Y)$